Primera part del projecte de Base de Dades (MF01)

1. Identificació del projecte: Nom, Autor, Objectiu i URL de Github

- Nom: CatchGENE
- Autor: Joan Pau Cebrià i Costa
- Objectiu: Desenvolupar el sistema de dades per a gestionar dades de trancriptòmica i epigenètica relacionats a cada gen
- url: https://github.com/JPCC0033/BBDD/tree/main/BBDD/projecte

2. Especificació de Requisits

Requisits d'Informació (Dades a emmagatzemar)

- Dels gens s'ha de guardar el seu nom i descripció.
- De cada experiment que és el resultat d'una seqüenciació s'ha de guardar la data de seqüenciació, la biosample d'on s'ha fet, quina plataforma de seqüenciació s'ha utilitzat i el tipus d'experiment que poden ser diferents tipus d'accessibilitat al DNA, diferents tipus de dades de transcripció, de diferents factors de transcripció o de diferents marques d'histona.
- Dels assemblies s'ha de saber de quin organisme està fet, la versió, quan es va fer, l'score busco que n'indica la qualitat i l'url on trobar-los.
- Dels organismes, el nom científic i el numero taxonòmic.
- Dels teixits el seu nom.
- Dels biosamples el seu nom, de quin teixit i organisme provenen, l'edat de l'organisme del teixit del qual es va obtenir el biosample, el sexe i el lot d'obtenció o compra.
- Dels gene_ontologies es vol saber el nom del gene_ontolgy i la descripció d'aquest agrupament de gens.

Regles de Negoci (Restriccions i fluxos)

- Un gen té un Transcription Start Site (TSS) i un transcription End Site (TES) diferent en cada assembly.
- Un assembly té la informació dels TSS i TES de tots els gens del genoma.
- Un experiment conté informació de seqüenciació de varis gens i un gen es pot trobar en varis experiments.
- Un gen pertany a un sol gene_ontology.
- Podem tenir teixits de varis organismes i varis teixits per organisme.
- D'una biosample es poden fer molts experiments.
- Cada biosample pertany a un únic teixit i a un únic organisme.

- Cada assembly és específic d'un organisme i en podem tenir varis per organisme
- Cada experiment està fet amb una plataforma de seqüenciació concreta.
- Cada experiment és o bé un experiment de transcription o d'accessibility al DNA o on s'ha utilitzat un factor de transcripció o s'ha utiltizat una marca d'histona.

3. Diagrama Entitat-Relació (Modelo Conceptual)

A partir dels requisits anteriors, identifiquem les entitats, els seus atributs i com es connecten entre si:

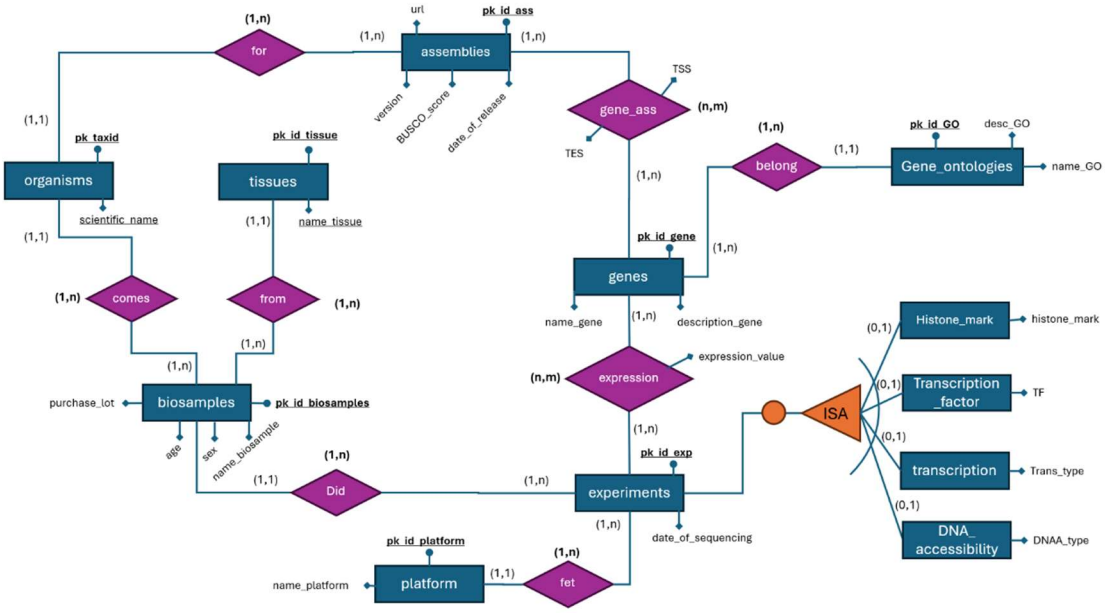
Entitats i Atributs

- genes: pk_id_gene (clau), name_gene, description_gene.
- gene_ontologies: pk_id_GO (clau), name_GO, desc_GO.
- assemblies: pk_id_ass (clau), version, date_of_release, busco_score, url.
- organisms: pk_taxid (clau), scientific name.
- tissues: pk_id_tissue (clau), name_tissue
- biosamples: pk_id_biosample (clau), name_biosample, age, sex, purchase_lot.
- experiments: pk_id_exp (clau), date_of_sequencing.
- platforms: pk_id_platform, platform_name.
- DNA_accessibility: id_DNAA (clau), DNAA_type.
- transcription: id_trans (clau), trans_type.
- Histone_mark: id_HM (clau), histone_mark
- Transcription_factor: id_TF (clau), TF.

Relacions i Cardinalitats

- expression (genes-experiments): Relació N:M. Un gen té un valor d'expressió en varis experiments, un experiment conté els valors d'expressió de varis.
- belong (genes-gene_ontologies): Relació 1:N: Un gene_ontology conté varis gens.
- gene_ass: (genes-assemblies): Relació N:M. Cada gen té un TSS i un TES específics de cada assembly. Cada assembly conté el TSS i el TES de varis gens.
- for (organisms-assemblies): Relació 1:N. Un organisme pot tenir molts assemblies.
- comes (biosamples-organisms): Relació 1:N. Una biosample prové d'un organisme. Un organisme pot tenir varies biosamples.
- from (biosamples-tissues): Relació 1:N. Una biosample prové d'un teixit, un teixit pot tenir varis biosamples.

- did (experiments-biosamples). Relació 1:N. D'un biosample podem tenir molts experiments però cada experiment pertany a una biosample.
- fet (experiments-platforms). Relació 1:N. Cada experiment està fet amb una plataforma de seqüenciació diferent però cada plataforma pot haver seqüenciat varis experiments
- ISA (experiment-Transcription_factor/Histone_mark/Transcription/DNA_accessibility). Relació 0:1. Un experiment ha de ser del tipus d'un d'aquests 4 elements obligatòriament i només un d'aquests



4. Model Relacional (Disseny Lògic)

Les Claus Primàries es mostren en negreta i subratllades.
Les Claus candidates es mostren subratllades.
Les Claus Foranies estan marcades com (fk).
Les taules intermitges degut a relacions n:m es troben en cursiva.

- GENES (**pk_id_gene**, name_gene, description_gene, fk_id_GO)

  on {fk_id_GO referencia a GENE_ONTOLOGIES.pk_id_GO}

- GENE_ONTOLOGIES (**pk_id_GO**, name_GO, desc_GO)
- ASSEMBLIES (**pk_id_ass**, version, date_of_release, busco_score, url, fk_taxid)

  on {fk_taxid referencia ORGANISMS.pk_taxid}

- *GENE_ASS* (**fk_id_gene+fk_id_ass,** TSS, TES)

  on {fk_id_gene referencia GENES.pk_id_gene}

  {fk_id_ass referencia ASSEMBLIES.pk_id_ass}

- ORGANISMS (**pk_taxid**, scientific_name)
- TISSUES (**pk_id_tissue**, name_tissue)
- BIOSAMPLES (**pk_id_biosample**, name_biosample, age, sex, purchase_lot, fk_id_taxid, fk_id_tissue)

  on {fk_id_taxid referencia ORGANISMS.pk_taxid}
  {fk_id_tissue referencia tissue.pk_id_tissue}
- *EXPRESSION* (**fk_id_gene+fk_id_exp**, expression_value)

  on {fk_id_gene referencia GENES.pk_id_gene}

  {fk_id_exp referencia EXPERIMENTS.pk_id_exp}
- EXPERIMENTS (**pk_id_exp**, date_of_sequencing, fk_id_platform, fk_id_biosample)

  on {fk_id_biosample referencia BIOSAMPLES.pk_id_biosample}

  {fk_id_platform referencia PLATFORMS.pk_id_platform}
- PLATFORMS (**pk_id_platform**, platform_name)
- DNA_accessibility (**pk_fk_id_exp**, DNAA_type)

  on {pk_fk_id_exp referencia EXPERIMENTS.pk_id_exp}
- Transcription (**pk_fk_id_exp**, trans_type)

  on {pk_fk_id_exp referencia EXPERIMENTS.pk_id_exp}
- Transcription_factor (**pk_fk_id_exp**, TF)

  on {pk_fk_id_exp referencia EXPERIMENTS.pk_id_exp}
- Histone_mark (**pk_fk_id_exp**, histone_mark)

  on {pk_fk_id_exp referencia EXPERIMENTS.pk_id_exp}

